Palestra · **Medindo agentes**

Como medir os seus agentes de IA

Do "parece que melhorou" para a eval

Mateus Castro · AI Engineer na Creditas

Quem é Mateus Castro?



AI Engineer na Creditas, com foco em soluções de IA.

Gol, Smiles, Neon, Dotz…

Formado em Ciência da Computação e pós em IA

Amante de esportes e carros

Casado com a Liz e pai da Éden

MÃO PARA CIMA

Quem aqui mede se o agente de código está melhorando?

- Não meço
- No feeling
- Tenho métrica

A aposta de hoje

Variante A

O repo **sem** `CLAUDE.md`

Variante B

O mesmo repo **com** `CLAUDE.md`

(o arquivo com as regras da casa)

```
pnpm eval
```

32

execuções, agora

FAÇAM A APOSTA

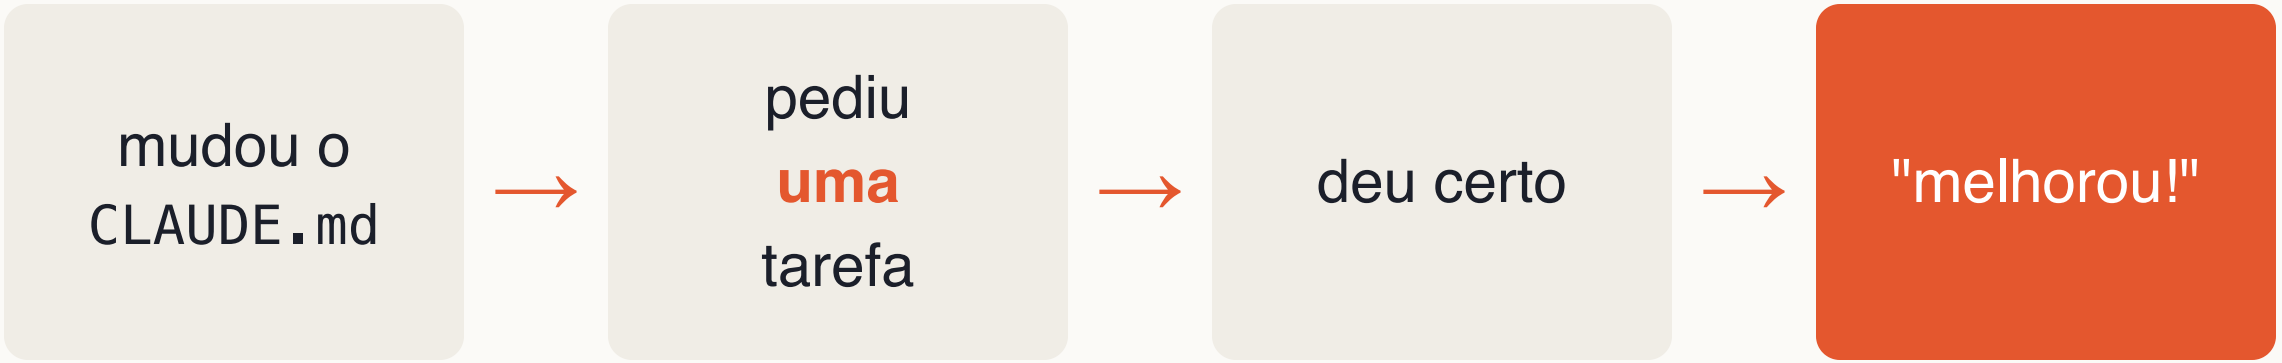
O `CLAUDE.md` vai fazer diferença?

B ganha

Empate

A ganha

"Parece que melhorou"



> **Daria certo antes da mudança também?**

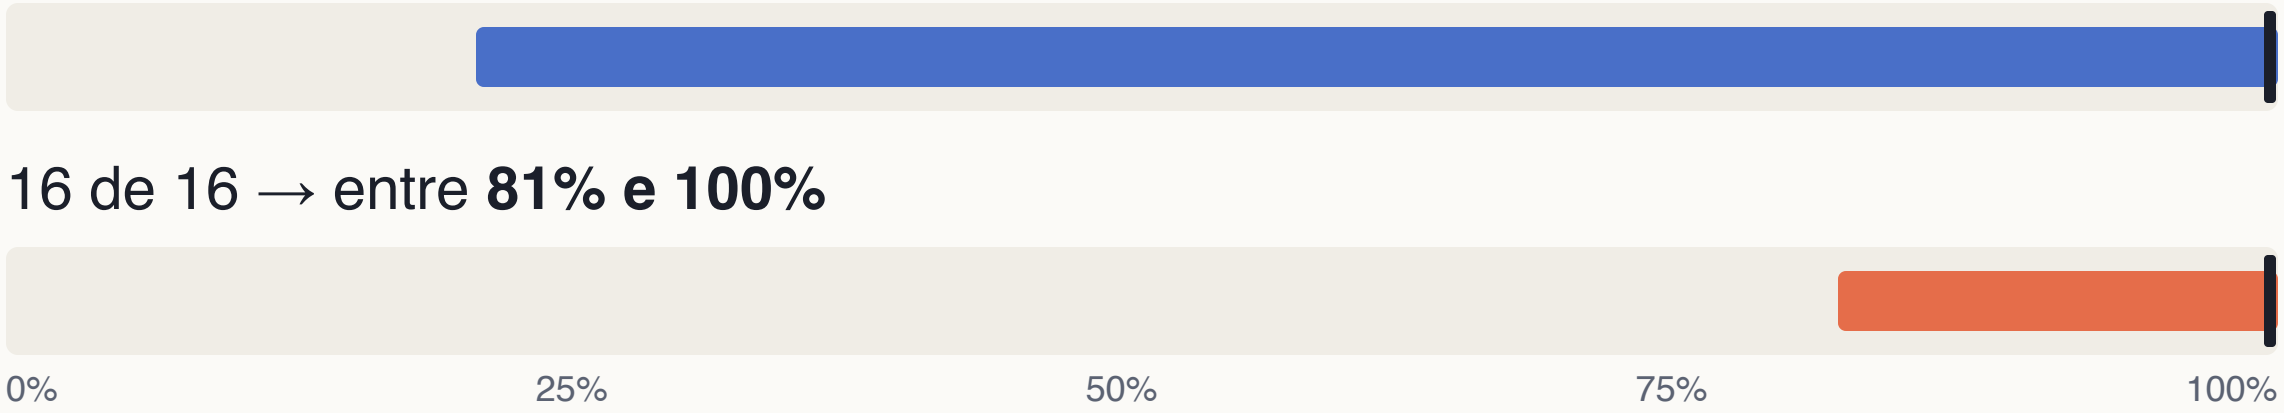
CHUTE ANTES DE EU MOSTRAR

1 de 1 é 100%. Confiam?

1 de 1 → o que a conta diz

1 de 1 → a taxa real pode estar entre **21% e 100%**

16 de 16 → entre **81% e 100%**



A faixa é a margem de erro, com 95% de confiança (intervalo de Wilson) · Wilson (1927)

As métricas de um agente de código

O que medir	Pergunta
Sucesso	deu certo? (o teste passou?)
Custo	quanto gastou?
Voltas	quantas idas e vindas deu?
Tempo	quanto demorou?
Escopo	mexeu onde não devia?
Consistência	resolve **sempre**?

O conjunto de hoje: 8 tarefas

5

dependem de uma regra da casa
que só o `CLAUDE.md` explica

3

de controle:
não dependem de regra nenhuma

Uma tarefa por dentro `03-evento-lotado`

> "…Não deixe inscrever em evento lotado…"

O agente só vê o pedido. O **teste escondido** confere:

- ✔ dá erro quando o evento lota
- ✔ é o erro do projeto, com código em MAIÚSCULAS (ex.: `EVENTO_LOTADO`)
- ✔ não reaproveita o código antigo, que significa outra coisa

Como uma execução roda

1 · CÓPIA

o agente trabalha numa cópia do app

→

2 · AGENTE

faz a tarefa, isolado, sem internet

→

3 · CORREÇÃO

um teste que ele não viu confere

promptfoo, "Javascript Provider" · Claude Code docs, "Run Claude Code programmatically"

IA como juiz (LLM-as-judge)

Ajuda

avalia o que teste não pega: clareza, estilo

Atrapalha

o juiz também varia: **soma incerteza**

> **Se dá para conferir com código, confira com código.**

Zheng et al. (2023), "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena" · promptfoo, "LLM Rubric"

O que conta como "deu certo"

resolvido | assistido | escalado | falta informação

> **Caso que nem era do agente, contado como falha, derruba a taxa.**

Eval que só melhora

- O gabarito é escrito por **gente**, do zero
- Os buracos de teste só **diminuem**
- Falhou na terça, **teste na quarta**

Uma mudança por vez

1
roda a eval
(o "antes")

→

2
muda
uma
coisa

→

3
roda de novo,
várias vezes

→

4
compara
as margens

Onde cada regra mora

	O que é	Quando vale
`CLAUDE.md`	texto com as regras do projeto	**toda** conversa
Skill	manual que ele abre se precisar	só quando usa
Hook	script que roda a cada ação dele	**sempre**

> **Regra que não pode falhar mora no hook, no teste ou no CI.**

Claude Code docs: "How Claude remembers your project" · "Extend Claude with skills" · "Hooks reference"

Ao vivo: o relatório

O relatório do run de hoje (`resultados/relatorio.html`) aparece aqui na apresentação em HTML.

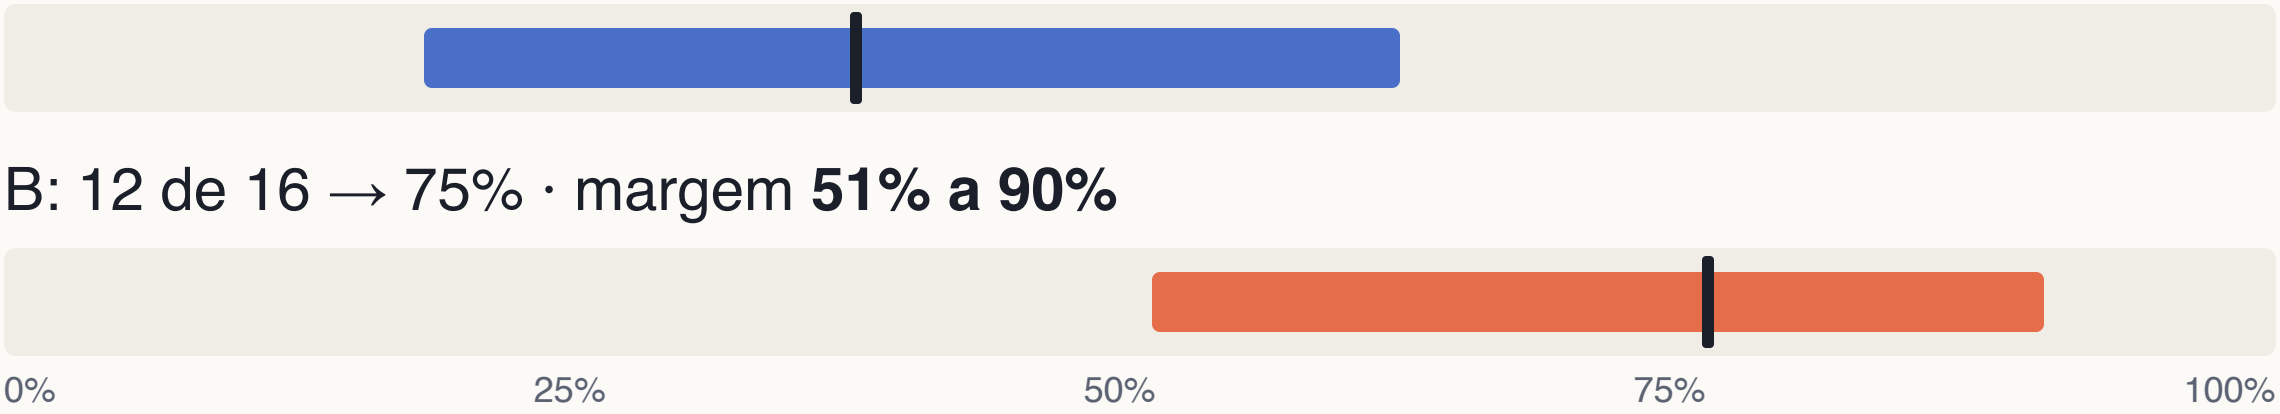
CHUTE ANTES DE EU MOSTRAR

B é o dobro de A. B ganhou?

6 de 16 × 12 de 16: o que a conta diz

A: 6 de 16 → 37,5% · margem **18% a 61%**

B: 12 de 16 → 75% · margem **51% a 90%**



> **As margens se cruzam: ainda não dá para saber.**

Exemplo ilustrativo, não é o run de hoje · margem = intervalo de Wilson 95% · Wilson (1927); Wikipedia, "Binomial proportion confidence interval"

CHUTE ANTES DE EU MOSTRAR

Quantas execuções de cada lado para ter certeza?

- 5?
- 16?
- 40?
- 200?

Para ter certeza

27

execuções de cada lado, no ensaio: A 12 de 16 × B 16 de 16

Leve para casa

1. Defina o que é **dar certo**
2. **Repita** e olhe a margem
3. Falha vira **tarefa nova**

Repo + ebook (PDF). Roda com o login do Claude Code.

Repo, ebook e slides

Referências

- promptfoo, "Javascript Provider": https://www.promptfoo.dev/docs/providers/custom-api/
- promptfoo, "Command line" (`--repeat`, `-j`, `-o`): https://www.promptfoo.dev/docs/usage/command-line/
- promptfoo, "LLM Rubric": https://www.promptfoo.dev/docs/configuration/expected-outputs/model-graded/llm-rubric/
- Claude Code, "Run Claude Code programmatically": https://code.claude.com/docs/en/headless
- Claude Code, "How Claude remembers your project": https://code.claude.com/docs/en/memory
- Claude Code, "Extend Claude with skills": https://code.claude.com/docs/en/skills
- Claude Code, "Hooks reference": https://code.claude.com/docs/en/hooks
- Anthropic (2026), "Demystifying evals for AI agents": https://www.anthropic.com/research/demystifying-evals-for-ai-agents
- Yao et al. (2024), "τ-bench" (pass^k): https://arxiv.org/abs/2406.12045
- Jimenez et al. (2023), "SWE-bench": https://arxiv.org/abs/2310.06770
- Zheng et al. (2023), "Judging LLM-as-a-Judge": https://arxiv.org/abs/2306.05685
- Intervalo de Wilson: https://en.wikipedia.org/wiki/Binomial_proportion_confidence_interval