Palestra · **Medindo agentes**

Como medir os seus agentes de IA

Do "parece que melhorou" para a eval

Mateus Castro · AI Engineer na Creditas

Quem é Mateus Castro?



AI Engineer na Creditas, com foco em soluções de IA.

Gol, Smiles, Neon, Dotz…

Formado em Ciência da Computação e pós em IA

Amante de esportes e carros

Casado com a Liz e pai da Éden

MÃO PARA CIMA

Quem aqui mede se o agente de código está melhorando?

- Não meço
- No feeling
- Tenho métrica

A aposta de hoje

Variante A

O repo **sem** `CLAUDE.md`

Variante B

O mesmo repo **com** `CLAUDE.md`

```
pnpm eval
```

32

execuções, agora

FAÇAM A APOSTA

O `CLAUDE.md` vai fazer diferença?

B ganha | **Empate** | **A ganha**

A resposta sai no **minuto 40**.

1 · O problema

Vibe check não é medida

"Parece que melhorou"

mudou o `CLAUDE.md` → pediu **uma** tarefa → deu certo → "melhorou!"

> **Daria certo antes da mudança também?**

O agente não é determinístico

Uma execução é **uma amostra**, não um resultado.

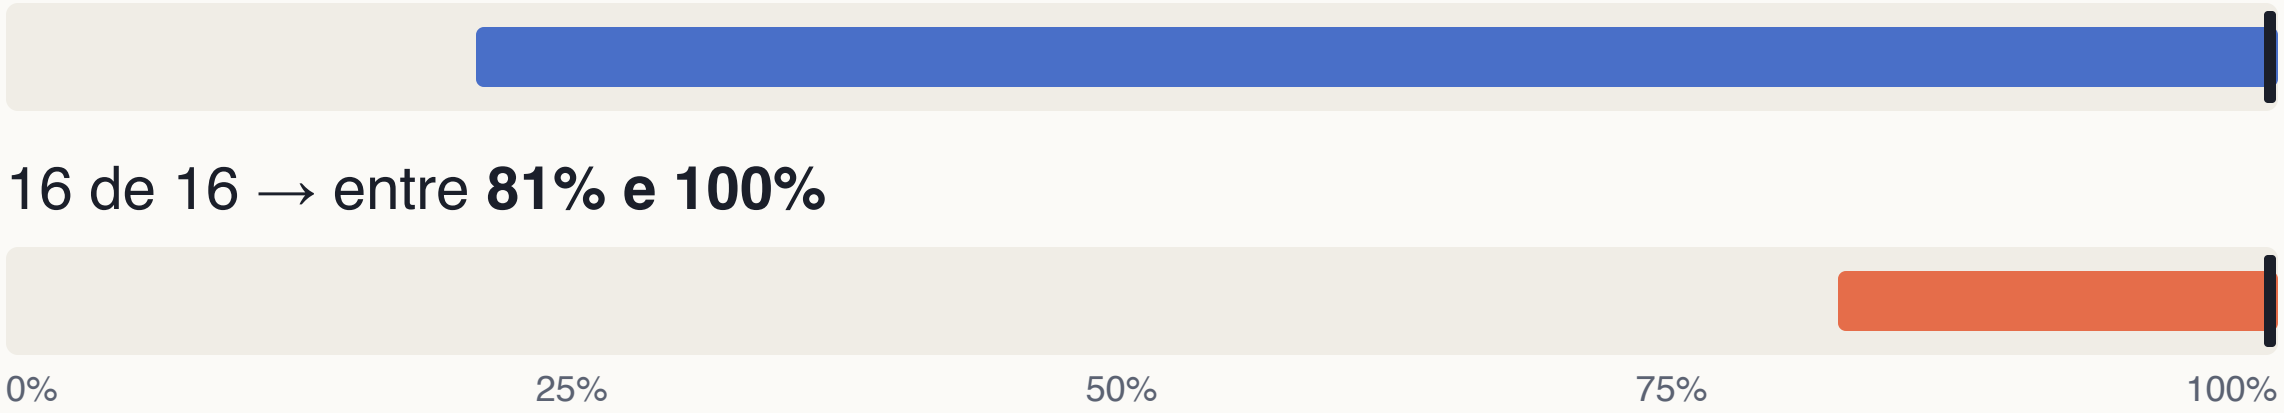
CHUTE ANTES DE EU MOSTRAR

1 de 1 é 100%. Confiam?

1 de 1 → o que a conta diz

1 de 1 → taxa real entre **21% e 100%**

16 de 16 → entre **81% e 100%**



Intervalo de Wilson, 95% · Wilson (1927)

2 · O que é "efetivo"

Seis números, não um

As métricas de um agente de código

Métrica	Pergunta
Sucesso	resolveu?
Custo / tokens	quanto gastou?
Turnos	quantas voltas deu?
Tempo	quanto demorou?
Fora do escopo	mexeu onde não devia?
Consistência	resolve **sempre**?

Sucesso sozinho engana

Resolveu mexendo onde não devia **não é sucesso**.

Um rótulo por execução

`passou` `falhou` `fora_do_escopo` `erro_agente`

> **`erro_agente` conta à parte: não é falha da tarefa.**

pass@k × pass^k

	Passou em…	Quando k cresce
pass@k	pelo menos **uma** de k	sobe ↑
pass^k	**todas** as k	desce ↓

> **Agente sozinho: vale o pass^k.**

pass^k: Yao et al. (2024), τ-bench · Anthropic (2026), "Demystifying evals for AI agents"

3 · Evals

Tarefa + critério de feito

O conjunto de hoje: 8 tarefas

5

dependem de uma convenção
que só o `CLAUDE.md` explica

3

controle:
não dependem

Uma tarefa por dentro 03-evento-lotado

> "…Não deixe inscrever em evento lotado…"

```
expect(erro).toBeInstanceOf(ErroDominio);
expect(codigo).toMatch(/^[A-Z][A-Z0-9_]*$/);
expect(codigo).toMatch(/LOTAD|CHEIO|CAPACIDADE|ESGOT|LIMITE|VAGA/);
expect(codigo).not.toBe("CAPACIDADE_INVALIDA");
```

Como uma execução roda

1 · CÓPIA LIMPA

app numa pasta temporária

→

2 · AGENTE

`claude -p` no sandbox

→

3 · CORREÇÃO

pasta nova + teste escondido

promptfoo, "Javascript Provider" · Claude Code docs, "Run Claude Code programmatically"

Duas camadas de eval

1 · Determinística

agente falso, offline,
a cada commit

2 · Modelo real

`pnpm eval`, consome cota,
quando algo muda

> **Sem a camada 1, bug no medidor parece "o agente piorou".**

LLM-as-judge

Ajuda

critério que teste não pega

Atrapalha

juiz variável **soma variância**

> **Se dá para verificar com código, verifique com código.**

Zheng et al. (2023), "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena" · promptfoo, "LLM Rubric"

4 · Caso real: agentes KTLO na Creditas

Lições, sem dados internos

O que conta como "deu certo"

resolvido | assistido | escalado | falta informação

> **Fora do escopo contado como falha derruba a taxa.**

CHUTE ANTES DE EU MOSTRAR

"Pare depois de N chamadas" no prompt. Funciona?

Teto de turnos: prompt ou hook?

> **Não:** o modelo não conta os próprios turnos.

> O teto de orçamento virou **hook**.

Lá, o juiz foi rejeitado

Juiz variável avaliando agente variável **soma variância**.

Eval que só melhora

- Gabarito humano nasce **vazio**
- Buracos de cobertura só **encolhem**
- Falhou na terça, **teste na quarta**

5 · Como melhorar

Uma mudança por vez

Uma mudança por vez

1
roda a eval (linha de base)

→

2
muda **uma** coisa

→

3
roda de novo, com repetições

→

4
compara intervalos

Onde cada regra mora

	Entra
`CLAUDE.md`	**toda** sessão
Skill	só quando é usada
Hook	em toda ferramenta

> **Regra que não pode falhar mora no hook, no teste ou no CI.**

Claude Code docs: "How Claude remembers your project" · "Extend Claude with skills" · "Hooks reference"

Falha vira tarefa nova

1

o agente erra
no dia a dia

→

2

tarefa +
teste escondido

→

3

entra no conjunto
e não sai

O portão no CI

- Inconclusivo → **passa**
- A melhor que B → **código 1**

> **Só quebra com evidência de piora.**

6 · Revelação

Vocês apostaram: B ganha · empate · A ganha

Ao vivo: o relatório `pnpm relatorio`

`resultados/relatorio.html`

trocar para o navegador

Plano B: `pnpm relatorio:ensaio`

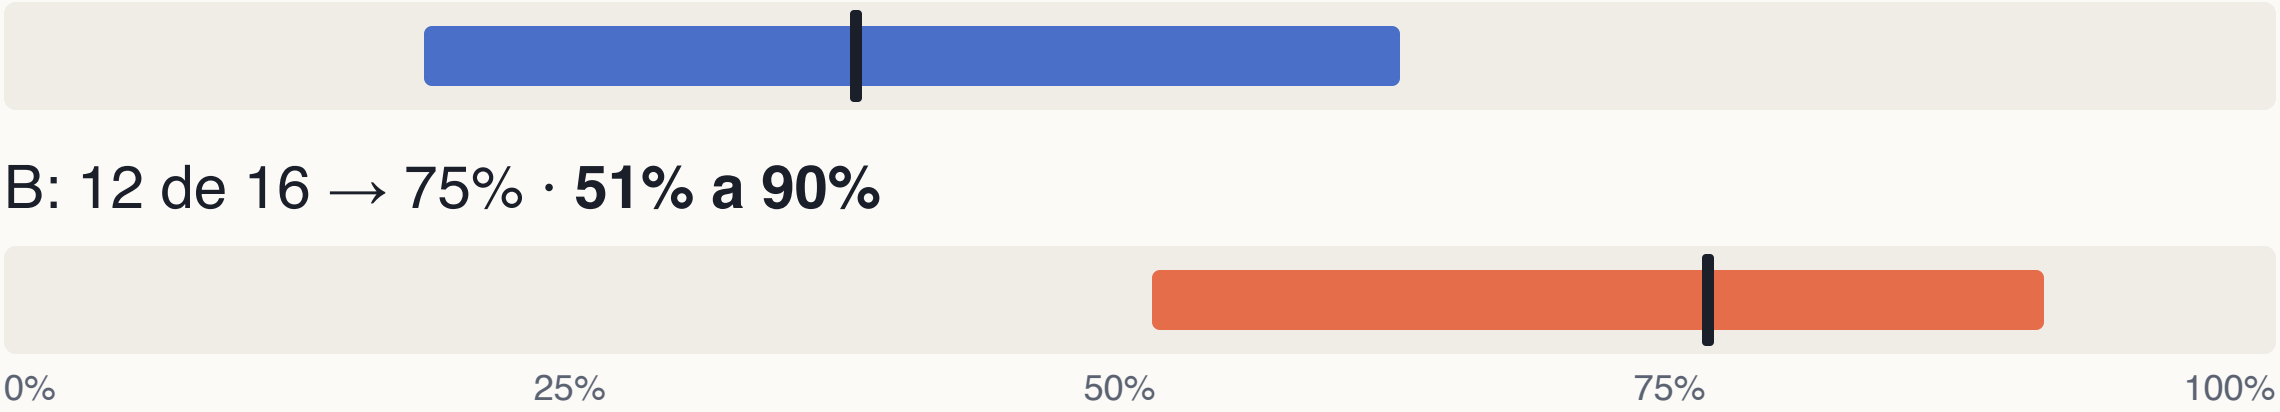
CHUTE ANTES DE EU MOSTRAR

B é o dobro de A. B ganhou?

6 de 16 × 12 de 16: o que a conta diz

A: 6 de 16 → 37,5% · **18% a 61%**

B: 12 de 16 → 75% · **51% a 90%**



> **As barras se sobrepõem: inconclusivo.**

Exemplo ilustrativo, não é o run de hoje · Wilson (1927); Wikipedia, "Binomial proportion confidence interval"

CHUTE ANTES DE EU MOSTRAR

Quantas execuções por variante para separar A de B?

5?

16?

40?

200?

Para separar A de B

27

execuções por variante, no ensaio: A 12/16 × B 16/16

Por que 16 não bastam

A	B	por variante
37,5%	75%	**27** (24)
62,5%	75%	**212** (212)

> **Diferença pequena, muitas execuções.**

Taxas de exemplo. O ensaio (75% × 100%) também dá 27 (24).

Leve para casa

1. **Desfecho** antes do número
2. **Repita**: intervalo, não execução
3. Falha vira **tarefa nova**

Repo + ebook (PDF). Roda com o login do Claude Code.

Repo, ebook e slides

Referências

- promptfoo, "Javascript Provider": https://www.promptfoo.dev/docs/providers/custom-api/
- promptfoo, "Command line" (`--repeat`, `-j`, `-o`): https://www.promptfoo.dev/docs/usage/command-line/
- promptfoo, "LLM Rubric": https://www.promptfoo.dev/docs/configuration/expected-outputs/model-graded/llm-rubric/
- Claude Code, "Run Claude Code programmatically": https://code.claude.com/docs/en/headless
- Claude Code, "How Claude remembers your project": https://code.claude.com/docs/en/memory
- Claude Code, "Extend Claude with skills": https://code.claude.com/docs/en/skills
- Claude Code, "Hooks reference": https://code.claude.com/docs/en/hooks
- Anthropic (2026), "Demystifying evals for AI agents": https://www.anthropic.com/research/demystifying-evals-for-ai-agents
- Yao et al. (2024), "τ-bench" (pass^k): https://arxiv.org/abs/2406.12045
- Jimenez et al. (2023), "SWE-bench": https://arxiv.org/abs/2310.06770
- Zheng et al. (2023), "Judging LLM-as-a-Judge": https://arxiv.org/abs/2306.05685
- Intervalo de Wilson: https://en.wikipedia.org/wiki/Binomial_proportion_confidence_interval