Palestra · **Medindo agentes**

Como medir os seus agentes de IA

Do "parece que melhorou" para a eval

Mateus Castro · AI Engineer na Creditas

Quem é Mateus Castro?



AI Engineer na Creditas, com foco em soluções de IA.

Gol, Smiles, Neon, Dotz…

Formado em Ciência da Computação e pós em IA

Amante de esportes e carros

Casado com a Liz e pai da Éden

MÃO PARA CIMA

Quem aqui mede se o agente de código está melhorando?

- Não meço
- No feeling
- Tenho métrica

A aposta de hoje

Variante A

O repo **sem** `CLAUDE.md`

Variante B

O mesmo repo **com** `CLAUDE.md`

(o arquivo com as regras da casa)

```
pnpm eval
```

32

execuções, agora

FAÇAM A APOSTA

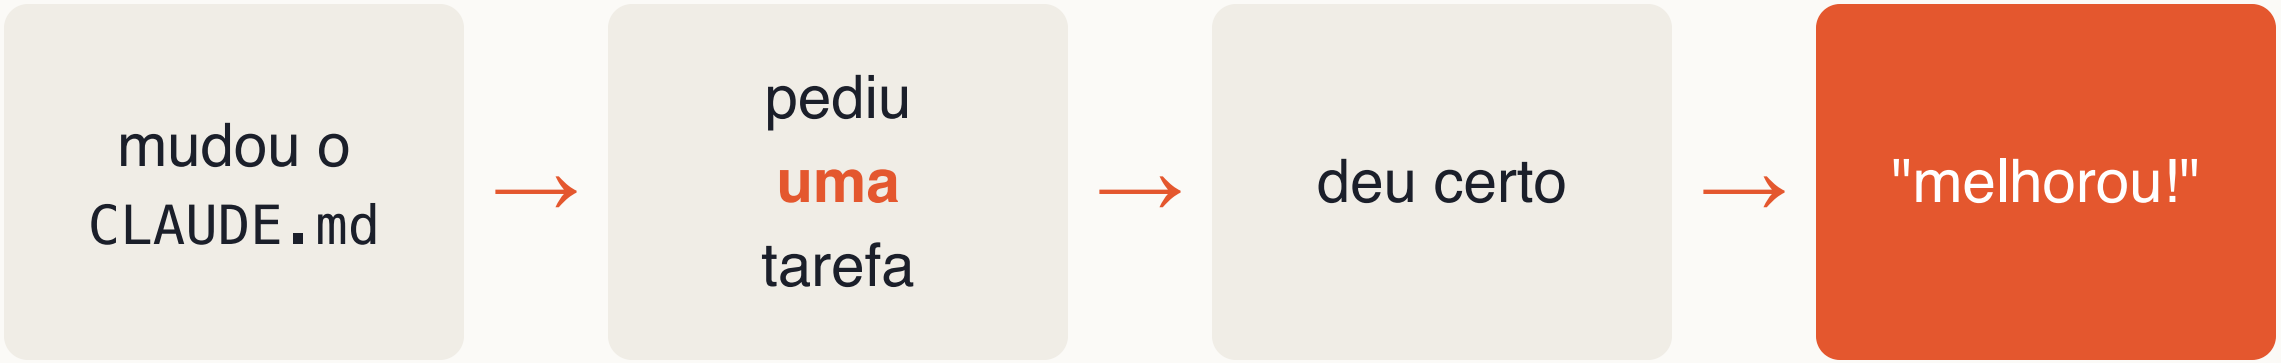
O `CLAUDE.md` vai fazer diferença?

B ganha

Empate

A ganha

"Parece que melhorou"



Daria certo antes da mudança também?

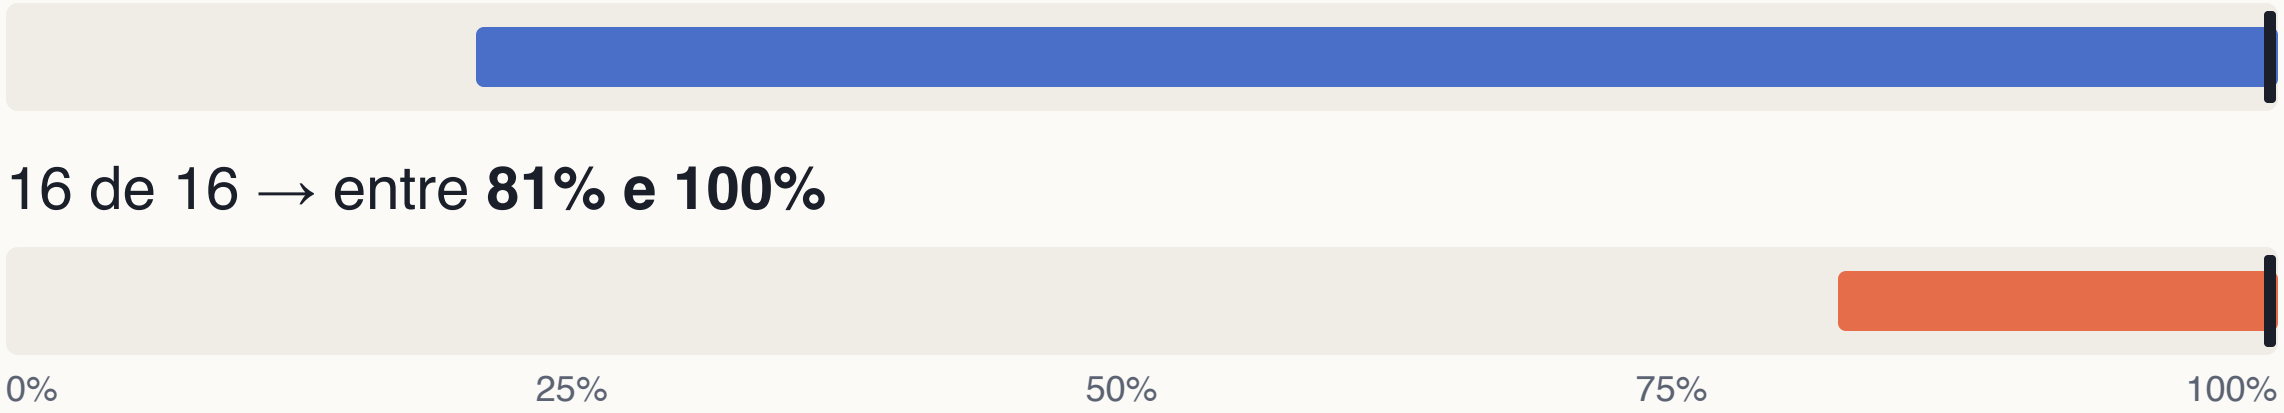
CHUTE ANTES DE EU MOSTRAR

1 de 1 é 100%. Confiam?

1 de 1 → o que a conta diz

1 de 1 → a taxa real pode estar entre **21% e 100%**

16 de 16 → entre **81% e 100%**



A faixa é a margem de erro, com 95% de confiança (intervalo de Wilson) · Wilson (1927)

As métricas de um agente de código

O que medir	Pergunta
Sucesso	deu certo? (o teste passou?)
Custo	quanto gastou?
Voltas	quantas idas e vindas deu?
Tempo	quanto demorou?
Escopo	mexeu onde não devia?
Consistência	resolve **sempre**?

O conjunto de hoje: 8 tarefas

5

dependem de uma regra da casa
que só o `CLAUDE.md` explica

3

de controle:
não dependem de regra nenhuma

Uma tarefa por dentro 03-evento-lotado

> "…Não deixe inscrever em evento lotado…"

O agente só vê o pedido. O **teste escondido** confere:

- ✔ dá erro quando o evento lota
- ✔ é o erro do projeto, com código em MAIÚSCULAS (ex.: `EVENTO_LOTADO`)
- ✔ não reaproveita o código antigo, que significa outra coisa

Como uma execução roda

1 · CÓPIA
o agente trabalha numa cópia do app

→

2 · AGENTE
faz a tarefa, isolado, sem internet

→

3 · CORREÇÃO
um teste que ele não viu confere

promptfoo, "Javascript Provider" · Claude Code docs, "Run Claude Code programmatically"

IA como juiz (LLM-as-judge)

Ajuda

avalia o que teste não pega: clareza, estilo

Atrapalha

o juiz também varia: **soma incerteza**

> **Se dá para conferir com código, confira com código.**

Zheng et al. (2023), "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena" · promptfoo, "LLM Rubric"

O que conta como "deu certo"

resolvido | assistido | escalado | falta informação

> **Caso que nem era do agente, contado como falha, derruba a taxa.**

Eval que só melhora

- O gabarito é escrito por **gente**, do zero
- Os buracos de teste só **diminuem**
- Falhou na terça, **teste na quarta**

Uma mudança por vez

1
roda a eval
(o "antes")

→

2
muda
uma
coisa

→

3
roda de novo,
várias vezes

→

4
compara
as margens

Onde cada regra mora

	O que é	Quando vale
`CLAUDE.md`	texto com as regras do projeto	**toda** conversa
Skill	manual que ele abre se precisar	só quando usa
Hook	script que roda a cada ação dele	**sempre**

> **Regra que não pode falhar mora no hook, no teste ou no CI.**

Claude Code docs: "How Claude remembers your project" · "Extend Claude with skills" · "Hooks reference"

Ao vivo: o relatório

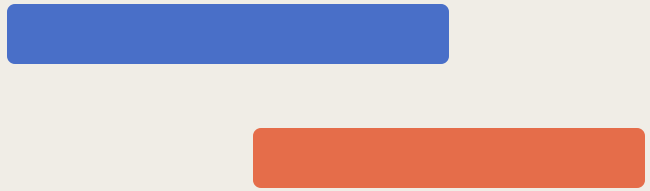
O relatório do run de hoje (`resultados/relatorio.html`) aparece aqui na apresentação em HTML.

CHUTE ANTES DE EU MOSTRAR

B acertou mais. Então B ganhou?

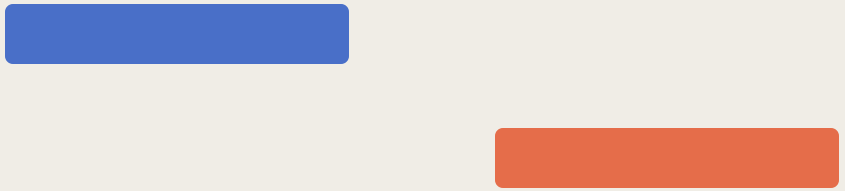
Quando dá para dizer quem ganhou

As faixas se cruzam



Ainda não dá para saber

As faixas se separam



Agora dá: B é melhor

Cada faixa é a margem de erro de uma variante (intervalo de Wilson 95%) · Wilson (1927); Wikipedia, "Binomial proportion confidence interval"

CHUTE ANTES DE EU MOSTRAR

Quantas execuções de cada lado para ter certeza?

5?

16?

40?

200?

Para ter certeza

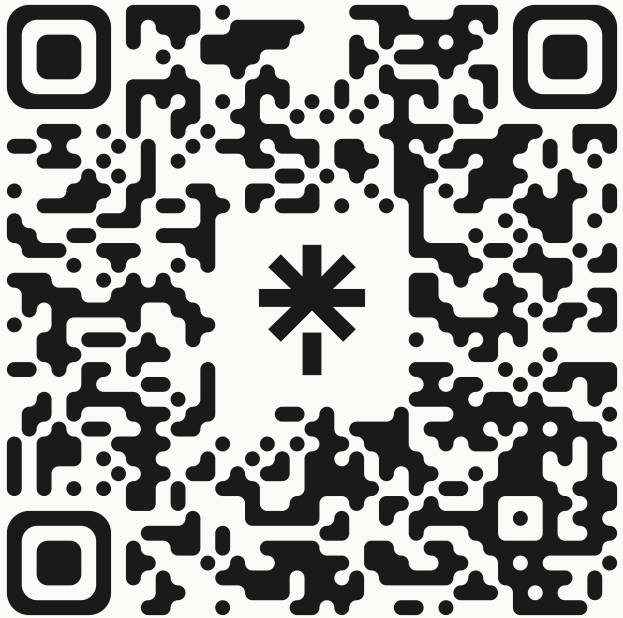
27

execuções de cada lado, no ensaio: A 12 de 16 × B 16 de 16

Leve para casa

1. Defina o que é **dar certo**
2. **Repita** e olhe a margem
3. Falha vira **tarefa nova**

Repo + ebook (PDF). Roda com o login do Claude Code.



Repo, ebook e slides

Referências

- promptfoo, "Javascript Provider": https://www.promptfoo.dev/docs/providers/custom-api/
- promptfoo, "Command line" (`--repeat`, `-j`, `-o`): https://www.promptfoo.dev/docs/usage/command-line/
- promptfoo, "LLM Rubric": https://www.promptfoo.dev/docs/configuration/expected-outputs/model-graded/llm-rubric/
- Claude Code, "Run Claude Code programmatically": https://code.claude.com/docs/en/headless
- Claude Code, "How Claude remembers your project": https://code.claude.com/docs/en/memory
- Claude Code, "Extend Claude with skills": https://code.claude.com/docs/en/skills
- Claude Code, "Hooks reference": https://code.claude.com/docs/en/hooks
- Anthropic (2026), "Demystifying evals for AI agents": https://www.anthropic.com/research/demystifying-evals-for-ai-agents
- Yao et al. (2024), "τ-bench" (pass^k): https://arxiv.org/abs/2406.12045
- Jimenez et al. (2023), "SWE-bench": https://arxiv.org/abs/2310.06770
- Zheng et al. (2023), "Judging LLM-as-a-Judge": https://arxiv.org/abs/2306.05685
- Intervalo de Wilson: https://en.wikipedia.org/wiki/Binomial_proportion_confidence_interval